

Lab Data Challenge 2026

Previsione di malfunzionamenti industriali

Gruppo 1 --- **ThreeShots**

Luca Iaria – Giacomo Fullin – Federico Mariani




14 maggio 2026



Obiettivo dell'analisi

- **Obiettivo:** Predizione dei malfunzionamenti (generici e specifici) tramite modelli di apprendimento supervisionato.
- **Feature Engineering:** Focus sulla creazione di indicatori derivati dai parametri industriali per modellare lo stato di usura dei componenti.
- **Validazione:** Valutazione delle performance basata sulla capacità predittiva delle classi di guasto su un test set non etichettato.



Descrizione variabili dataset

Il dataset contiene 8000 osservazioni di natura sequenziale

Sono organizzati in 12 variabili



Parametri operativi

- Rotazioni per Ora
- Coppia Rotazione (Nm)
- Tempo Lavorazione (mins)
- Fascia Prodotto (Base, Media, Alta)
- Temperatura esterna (C)
- Temperatura Processo (C)



Target di malfunzionamento

- Malfunzionamento
- Malfunzionamento_tipo1
- Malfunzionamento_tipo2
- Malfunzionamento_tipo3
- Malfunzionamento_tipo4
- Malfunzionamento_tipo5


Analisi Descrittiva del Dataset

VARIABILE	MEDIA	DEV. STANDARD	MIN	MAX
Rotazioni per Ora	25.664	3.043	19.467	48.100
Coppia Rotazione	39.977	10.046	3.800	76.600
Tempo Lavorazione	108.377	63.783	0.000	253.000
Temp. Esterna	27.256	1.999	22.150	31.350
Temp. Processo	37.008	1.536	32.550	40.650

FASCIA PRODOTTO	FREQUENZA (N)	PERCENTUALE (%)
ALTA	782	9.775%
MEDIA	4.816	60.200%
BASE	2.402	30.025%


Analisi delle Classi e Data Cleaning

1. SBILANCIAMENTO DELLE CLASSI



Dataset fortemente sbilanciato, tipico di contesti industriali.

2. RISOLUZIONE ANOMALIE E DATA CLEANING



INCOERENZA GUASTI "ORFANI"

7 osservazioni "Guasto Generale" (1) prive di tipologia specifica.



Decisione: Riclassificate come "Sane" per pulizia segnale.



ANOMALIA MALFUNZIONAMENTO TIPO 5

Presenza Tipo 5 (18 casi) non attivava il target generale.



Decisione: Esclusione della categoria per garantire coerenza.



Esplorazione Dati



Feature engineering



Potenza

prodotto tra velocità e coppia. Rappresenta la potenza meccanica del processo



Indice Resistenza

rapporto tra coppia e rotazioni. Indica la "fatica" del macchinario ad ogni singolo giro.



Num Rotazioni

stima del numero totale di rotazioni in un singolo ciclo.

Combina velocità e durata per quantificare il lavoro meccanico del singolo pezzo.



Delta Termico

differenza tra temperatura di processo e temperatura esterna. Evidenzia la capacità del sistema di dissipare calore, valori anomali indicano surriscaldamento o raffreddamento insufficiente.



Sforzo Usura

calcolato come il prodotto tra il tempo di lavorazione e la coppia di rotazione. Questa variabile permette di pesare la durata del ciclo con l'intensità della forza applicata.




Varianza Mobile Coppia


la varianza mobile su una finestra di 5 osservazioni monitora la stabilità del carico meccanico. Serve per rilevare le vibrazioni e l'instabilità meccanica.





Malf tipo 1 – Sforzo Prolungato





Distribuzione di Densità: Numero Rotazioni
Confronto basato sul Malfunzionamento di tipo 1





Malf tipo 2 – Surriscaldamento




Malf tipo 3 – Sovraccarico di Potenza



Malf tipo 4 – Stress Meccanico






Modellistica


Approccio multi-modello

- Nessun rimescolamento per evitare Data Leakage temporale
- Modelli binari indipendenti per catturare le firme specifiche di ogni malfunzionamento



Prevenire il Data Leakage

- **Problema:** I guasti sono una netta minoranza. Usare metodi standard porterebbe il modello a imparare a memoria la classe maggioritaria.
- Strategia di bilanciamento tramite **Oversampling (SMOTE)** sui Guasti.
- Il campionamento viene applicato **solo sui Fold di Training**. Il Validation Set rimane intatto, reale e sbilanciato per misurare le vere performance.



Random Forest: Eccellenza Predittiva per Mal 2, 3 e 4

L'algoritmo Random Forest ha dimostrato la massima capacità di generalizzazione, catturando relazioni non lineari nei dati dei sensori meglio di altri modelli testati.


**PARAMETRI DEI MODELLI RANDOM FOREST
PER LA PREDIZIONE DEI Malfunzionamenti**

TIPO DI Malfunzionamento	PARAMETRI RANDOM FOREST					BACC
	ntrees	mtry	nodesize	maxnodes	soglia*	
	Numero di Alberi	Variabili per Split	Dimensione Minima Nodo	Nodi Massimi	Valore di Soglia	Balanced Accuracy
Malfunzionamento 2	662	8	11	255	0.716	1.00
Malfunzionamento 3	725	6	18	233	0.4062	1.00
Malfunzionamento 4	801	8	4	126	0.4919	1.00

Cause fisiche dei malfunzionamenti


Le variabili evidenziate dai modelli Random Forest confermano la natura fisica dei guasti riscontrati.

Malfunzionamento 2:




Driver principale: dissipazione insufficiente

Malfunzionamento 3:



Driver principale: eccesso di potenza

Malfunzionamento 4:



Driver principale: Sforzo operativo elevato

Un caso più complesso: malfunzionamento tipo 1

A differenza degli altri malfunzionamenti, il Tipo 1 ha mostrato una maggiore complessità. Dopo aver testato anche altri modelli come SVM e Gradient Boosting, l'algoritmo **Random Forest** è stato selezionato per la sua robustezza contro l'overfitting e la capacità di catturare interazioni non lineari tra i sensori.



Iperparametri Ottimali


PARAMETRI DEL MODELLO RANDOM FOREST PER IL MALFUNZIONAMENTO 1

TIPO DI MALFUNZIONAMENTO	PARAMETRI RANDOM FOREST					BACC
	ntrees	mtry	nodesize	maxnodes	soglia*	
	Numero di Alberi	Variabili per Split	Dimensione Minima Nodo	Nodi Massimi	Valore di Soglia	
Malfunzionamento 1	507	8	5	193	0.0049	0.8704



Variabili determinanti

RF Variable Importance (Mal1)



Il caso malfunzionamento tipo 5

0%

prevedibilità fisica

Natura Stocastica:

Il Malfunzionamento Tipo 5 rappresenta guasti puramente casuali. L'assenza di pattern correlati nei sensori rende controproducente l'uso del Machine Learning.

Decisione: Gestione reattiva per evitare un eccesso di falsi allarmi industriali.

Conclusioni e sviluppi futuri




Completa efficacia sui tipi 2/3/4

I dati attualmente estratti dai macchinari descrivono in modo completo le anomalie di tipo 2, 3, 4. Le variabili a disposizione permettono ai modelli di raggiungere **un'accuratezza eccellente**, rendendo il monitoraggio per questi guasti altamente affidabile.



La sfida del Tipo 1

Nonostante l'algoritmo Random Forest sia riuscito a estrarre valore dai dati isolando il guasto (BACC 0.87), risulta evidente che **le variabili attuali non catturano completamente la fenomenologia fisica** alla base del Malfunzionamento Tipo 1.



Hardware upgrade

Raccomandata **l'installazione di sensori aggiuntivi** mirati. L'implementazione di sensori aggiuntivi (*vibrazione ad alta frequenza o analisi acustica*) permetterebbe di raccogliere le variabili chiave necessarie a perfezionare la predizione del Tipo 1.